

HW6: 50 Startups 獲利預測分析技術白皮書

副標題：以 CRISP-DM、scikit-learn Pipeline、特徵選擇與商業專家共識建立可解釋的迴歸模型

版本：v2 技術白皮書 | 日期：2026-06-11 | 資料集：Kaggle 50 Startups

CRISP-DM 技術白皮書 workflow

從商業理解到專家導向結論，確保模型不只準確，也能被商業決策採用。




圖 0-1：本白皮書整體 workflow 與分析主軸

執行摘要

本白皮書整理 HW6 「50 Startups Regression with CRISP-DM」專案的完整技術設計、模型實驗、評估結果與商業結論。研究對象為 Kaggle 50 Startups 資料集，任務是使用企業在 R&D Spend、Marketing Spend、Administration 以及 State 等欄位來預測 Profit。雖然此資料集規模不大，只有 50 筆資料，但它非常適合用來展示資料科學專案如何從商業問題出發，逐步走向可執行、可驗證、可解釋的機器學習模型。

本專案的核心不只是把所有欄位丟進線性迴歸模型，而是根據 CRISP-DM 方法與多領域專家討論，設計一組由簡到繁的特徵實驗。這種設計可以回答「哪些欄位真正有幫助」、「增加欄位是否真的改善泛化能力」、「State 是否只是背景變數」、「Administration 是否會帶來雜訊」等問題。比起單一模型結果，這樣的實驗設計更接近真實商業分析情境。

五組主要模型實驗顯示，Model A 僅使用 R&D Spend 便取得最佳測試集結果，RMSE 為 7,714.33， R^2 為 0.9265，Adjusted R^2 為 0.9173。隨著特徵數量增加，模型的測試誤差反而上升，代表在小樣本資料集中，加入不穩定或弱解釋力特徵可能降低模型泛化能力。這個結果符合 Occam’s Razor 原則：在能夠解釋問題的前提下，較簡潔的模型通常更穩健。

多領域專家五回討論後的結論是：R&D Spend 是最核心的獲利驅動因素，代表產品開發、技術能力與創新能力；Marketing Spend 是重要輔助，能放大產品價值與市場曝光；Administration 代表營運與管理成本，可能不穩定；State 可作為地區背景觀察，但在樣本數只有 50 的情況下不應過度解讀。最終模型選擇不應只看 R^2 ，而應同時考慮 Adjusted R^2 、RMSE、MAE、係數方向、模型複雜度與商業邏輯。

白皮書章節導覽

章節	內容重點
1	專案概述與商業問題
2	CRISP-DM 工作流程設計
3	資料理解與欄位語意分析
4	資料準備與 sklearn Pipeline 架構
5	模型設計與五組商業導向特徵實驗
6	評估指標與模型選擇準則
7	特徵選擇演算法比較
8	結果可視化與圖表解讀
9	專家共識與商業洞察
10	部署、風險、限制與後續改進
附錄	YAML Prompt v2 與參考程式架構

1. 專案概述與目標

50 Startups 資料集是一個經典的多元線性迴歸練習資料。它的結構非常直觀：每一列代表一家新創公司，每家公司都有三個主要支出欄位、所在地州別以及最終利潤。這種資料非常適合用來說明從商業問題到資料建模的完整流程，因為每個欄位都能對應到一個真實的商業活動。

本專案將目標變數設定為 Profit，並將 R&D Spend、Marketing Spend、Administration 與 State 視為候選特徵。由於 Profit 是連續型數值，本題屬於監督式學習中的迴歸問題。演算法上，我們以 LinearRegression 作為主模型，因為它具備簡潔、可解釋與容易連結商業含義等優點。

白皮書的定位不是單純展示程式輸出，而是提供一份可以被技術人員、商業分析人員與教學評分者共同理解的分析文件。因此內容涵蓋商業理解、資料理解、特徵工程、模型實驗、評估準則、圖表解釋、風險限制與後續部署建議。

在專案目標上，我們希望回答三個層次的問題。第一是預測層次：能否建立一個準確預測 Profit 的模型。第二是解釋層次：哪些特徵對 Profit 最有貢獻。第三是決策層次：模型結果能否協助企業思考資源配置，尤其是研發、行銷與行政成本之間的優先順序。

1.1 商業問題定義

新創公司常面臨資源有限的困境。資金要投入研發、行銷、行政管理或市場拓展，都會影響公司的成本結構與獲利能力。如果資源投入方向錯誤，短期可能造成現金流壓力，長期則可能削弱產品競爭力；相反地，如果企業能把資源投向真正產生利潤的環節，就能提高經營績效。

因此，本專案的商業問題可以定義為：在新創企業的支出結構中，哪些投入最能解釋最終利潤？以及我們是否可以利用這些支出資料建立一個具備泛化能力的預測模型？這個問題同時具有統計分析與商業決策兩種意義。

從投資人角度看，模型可以協助判斷一家新創公司的支出配置是否合理；從創辦人角度看，模型可以協助評估資源是否應優先投入產品研發；從財務分析角度看，模型可以提供預算規劃與成本控管的量化參考。

1.2 技術問題定義

技術上，本題可形式化為迴歸問題。輸入 X 由不同的商業特徵組成，輸出 y 為 Profit。模型學習的目標是估計特徵與利潤之間的線性關係，並在測試集上產生盡可能小的預測誤差。

線性迴歸雖然不是最複雜的模型，但在本資料集上非常合適。原因有三：第一，資料量很小，複雜模型容易過度擬合；第二，專案重視解釋性，線性係數能直接對應欄位影響方向；第三，教學目標在於理解特徵與目標變數的關係，而非追求黑箱模型。

本專案同時使用 sklearn Pipeline、ColumnTransformer 與 OneHotEncoder 來建立穩定的流程。這樣的設計可以避免在訓練集與測試集之間產生不一致的資料轉換，也能降低資料洩漏風險。



圖 1-1：使用者提供之 HW6 視覺摘要，呈現 CRISP-DM、模型實驗與最終結論

2. CRISP-DM 專案工作流程

CRISP-DM 是 Cross-Industry Standard Process for Data Mining 的縮寫，常被用來規範資料探勘與機器學習專案的端到端流程。它把專案分成六個階段：商業理解、資料理解、資料準備、建模、評估與部署。對於 50 Startups 這種看似簡單的迴歸題，CRISP-DM 的價值在於避免我們直接跳到程式碼，而忽略問題背景與模型結果的實際意義。

CRISP-DM 技術白皮書 workflow

從商業理解到專家導向結論，確保模型不只準確，也能被商業決策採用。




圖 2-1：本專案的 CRISP-DM workflow

2.1 商業理解

在商業理解階段，我們先定義獲利預測的目的與使用情境。模型不是為了單純得到漂亮分數，而是要協助理解資源配置。此階段特別強調 R&D、Marketing、Administration 與 State 的商業語意，並設定模型成功標準。

2.2 資料理解

資料理解階段檢查資料欄位、型態、缺失值、重複值與初步統計。這個階段也會觀察每個欄位是否具有明確商業含義，以及是否需要轉換。例如 State 是類別欄位，不能直接進入線性迴歸，需要 One-Hot Encoding。

2.3 資料準備

資料準備階段建立可重複的前處理流程。使用 Pipeline 與 ColumnTransformer 的好處是把資料轉換與模型訓練封裝在同一個物件中，確保訓練與測試流程一致。對小型資料集而言，這種嚴謹性尤其重要。

2.4 建模

建模階段不只建立全特徵模型，而是設計五組特徵實驗。Model A 使用 R&D Spend，Model B 加入 Marketing，Model C 再加入 Administration，Model D 使用所有特徵與 State，Model E 只使用 State。

2.5 評估

評估階段同時使用 RMSE、MAE、 R^2 與 Adjusted R^2 。單看 R^2 可能造成誤導，因為加入更多特徵通常會讓訓練解釋力上升，但不一定改善測試泛化能力。Adjusted R^2 與 RMSE 更能反映特徵增加是否真的有價值。

2.6 部署與結論

部署階段在本作業中不是建立 API 或上線系統，而是輸出一份可被理解與檢核的技術結論。最重要的是把模型結果轉換成決策語言：R&D 是核心，Marketing 是放大器，Administration 與 State 需謹慎解讀。

3. 資料理解與欄位語意分析

資料理解是本專案的關鍵。雖然資料集只有五個欄位，但每個欄位背後都代表不同的商業機制。若只從欄位名稱出發，很容易做出過度簡化的解釋；因此本章會從資料型態、商業語意、模型角色與潛在風險四個角度分析欄位。

本資料集包含 50 家新創企業。欄位 R&D Spend、Administration 與 Marketing Spend 是數值型特徵，State 是類別型特徵，Profit 是目標變數。資料量小意味著模型很容易受到特定切分、離群點或弱特徵影響，因此需要特別強調實驗設計與模型穩健性。

欄位	中文說明	資料型態	模型角色	專家解讀
R&D Spend	研發支出	數值型	核心特徵	代表產品與技術能力，預期最重要
Marketing Spend	行銷支出	數值型	輔助特徵	能放大產品價值，但可能與公司規模重疊
Administration	行政支出	數值型	待驗證特徵	可能是必要成本，也可能是雜訊
State	公司所在州別	類別型	輔助背景特徵	需 One-Hot Encoding，不宜過度解讀
Profit	公司利潤	數值型	目標變數	迴歸模型預測對象

3.1 R&D Spend：最核心的獲利驅動因子

R&D Spend 代表公司投入研究、產品開發、技術改善與創新的資金。對新創公司而言，產品或技術能力通常是競爭力的根源。若公司能持續投入研發，可能創造更好的產品、更高的技術壁壘與更強的市場差異化，進而提高利潤。從模型角度看，R&D Spend 通常與 Profit 有最強正相關，因此它被視為最重要候選特徵。

3.2 Marketing Spend：重要但需搭配產品力解讀

Marketing Spend 代表廣告、品牌推廣、市場活動與銷售曝光支出。行銷可以讓產品觸及更多客戶，提升品牌知名度與銷售機會。然而，行銷的效果往往取決於產品本身是否具備價值。如果產品競爭力不足，行銷支出可能無法有效轉換成利潤。因此 Marketing Spend 是重要輔助特徵，但它的邊際貢獻必須透過實驗驗證。

3.3 Administration：最需要懷疑的數值特徵

Administration 代表行政、人事、管理、辦公室與內部流程成本。這些成本是公司營運所必需，但不一定直接帶來收入。高行政支出可能代表公司規模較大，也可能代表管理效率較低。因此它在模型中可能提供一些公司規模訊號，也可能只是增加噪音。專家角度會先保留它進行實驗，而不是直接認定有用。

3.4 State：可觀察但不可過度詮釋

State 代表公司所在州別，例如 New York、California 或 Florida。它可能反映市場規模、稅務政策、人力成本、創業資源與顧客結構差異。不過，資料只有 50 筆，州別類別也有限，若直接從模型係數推論某州一定較有利，會造成過度解讀。因此 State 應透過 One-Hot Encoding 加入模型比較，但結論必須保守。

3.5 Profit：模型預測的核心結果

Profit 是本題目標變數，也是所有模型要預測的連續型數值。由於 Profit 不是類別，而是金額，因此適合使用迴歸模型。評估時必須關注預測誤差大小，例如 RMSE 與 MAE，因為商業上更在乎模型預測與實際利潤差多少，而不只是統計解釋力。

4. 資料準備與 sklearn Pipeline 技術架構

資料準備階段的目標是把原始資料轉換成模型可接受的形式，同時確保流程可重複、可維護且不造成資料洩漏。對 50 Startups 而言，主要挑戰不是資料清洗，而是如何正確處理 State 這個類別欄位，並把不同實驗的前處理邏輯統一在相同框架中。

本專案採用 sklearn Pipeline 與 ColumnTransformer。Pipeline 負責把前處理器與 LinearRegression 組合成一個完整模型；ColumnTransformer 則負責指定哪些欄位需要 One-Hot Encoding，哪些欄位直接通過。這樣的設計比手動先轉換整份資料更安全，因為轉換器會在訓練集 fit，再用同樣規則 transform 測試集。

4.1 主要技術堆疊

元件	用途	本專案中的角色
pandas	資料讀取與表格操作	讀取 CSV、檢查資料結構、整理結果表
numpy	數值運算	計算 RMSE、處理指標
train_test_split	資料切分	固定 80/20 與 random_state=42
ColumnTransformer	欄位分流前處理	對 State 編碼，數值欄位 passthrough
OneHotEncoder	類別欄位轉數值	State 使用 drop=first 避免虛擬變量陷阱
Pipeline	流程封裝	結合前處理與 LinearRegression
LinearRegression	模型訓練	建立可解釋的迴歸模型

4.2 為何使用 OneHotEncoder(drop="first")

線性迴歸無法直接處理文字類別，因此 State 必須轉成數值欄位。One-Hot Encoding 會把每個州別轉換成 0/1 欄位。若三個州別全部保留，這些欄位之間會存在完全線性相依，造成 dummy variable trap。使用 drop="first" 可以移除其中一個基準類別，讓模型係數更穩定。

需要注意的是，drop="first" 並不代表被移除的州別不重要，而是把它作為比較基準。例如保留 State_New York 與 State_Florida 時，模型係數代表相對於基準州別的差異。這種差異在小樣本資料中只能視為探索性訊號，不能做強因果推論。

4.3 防止資料洩漏的設計

資料洩漏是機器學習專案常見風險。若在切分訓練集與測試集之前就對整份資料做 fit，例如對 State 的全部類別或對數值特徵做標準化，測試集資訊可能間接進入訓練流程。雖然本題的 One-Hot Encoding 風險相對較低，但使用 Pipeline 仍是更穩健的工程做法。

在本專案中，每個實驗都透過同一個 run_experiment 函式執行。該函式內部先切分資料，再建立 Pipeline，最後訓練與預測。這讓五組模型的差異只來自特徵組合，而不是流程不一致。

5. 商業導向之特徵工程實驗

本專案最重要的設計是五組特徵實驗。這些實驗不是隨機排列，而是依照專家對四個特徵的商業理解逐步加入特徵。此設計能檢查每個新增欄位是否真的提升模型表現，並避免一開始就使用所有特徵造成解讀混亂。

模型	使用特徵	實驗目的	商業假設
Model A	R&D Spend	測試最核心單一特徵	研發投入可能已能解釋大部分 Profit
Model B	R&D Spend + Marketing Spend	檢查行銷是否增加價值	Marketing 可放大產品價值與市場曝光
Model C	R&D + Marketing + Administration	檢查行政支出是否有幫助	Administration 可能是成本或規模訊號
Model D	All features including State	檢查州別是否改善模型	State 可能包含區域差異
Model E	State only	檢查地點本身是否有預測力	單靠 State 通常不足以預測 Profit

5.1 Model A : R&D Spend Only

Model A 是本專案的核心基準模型。它只使用 R&D Spend 預測 Profit，目的在於檢查單一最重要特徵是否已具備足夠解釋力。結果顯示此模型在測試集上取得最佳 RMSE 與 R^2 ，代表 R&D Spend 本身已高度捕捉 Profit 的主要變異。這個結果也符合商業邏輯，因為研發投入直接連結產品力與創新能力。

5.2 Model B : R&D Spend + Marketing Spend

Model B 在 R&D 基礎上加入 Marketing Spend，用來測試行銷是否帶來額外資訊。理論上，行銷支出可以提升產品曝光與銷售機會，因此可能改善預測。但實驗結果顯示測試 RMSE 反而上升，表示在此資料切分下，Marketing 並沒有帶來足夠穩定的增益。這不代表 Marketing 在商業上無用，而是代表其在此小型資料集中的邊際預測效果不如預期。

5.3 Model C : 加入 Administration

Model C 進一步加入 Administration，用來檢驗行政支出是否是有用特徵。實務上，行政支出可能反映公司規模，也可能只是營運成本。結果顯示加入 Administration 後模型未明顯改善，符合專家對此欄位的保守判斷：Administration 應被視為待驗證特徵，而非核心驅動因子。

5.4 Model D：加入 State

Model D 使用所有特徵，包含 State 的 One-Hot Encoding。這個模型檢查地區資訊是否能補充財務特徵。若 State 明顯改善 RMSE 或 Adjusted R²，代表地區可能具有額外解釋力；但本次結果並未支持 State 成為主要預測變數。由於樣本數小，State 係數也不適合被解讀為某州的絕對優劣。

5.5 Model E：State Only

Model E 故意只使用 State 預測 Profit。這是一個診斷性實驗，目的不是建立好模型，而是確認位置本身是否足以解釋利潤。結果通常會很差，代表公司所在地不能單獨決定獲利能力。這支持最終結論：State 可以觀察，但不是核心特徵。

6. 模型效能與可視化分析

模型評估結果顯示，最簡潔的 Model A 反而在測試集上表現最佳。這個現象對資料科學專案非常重要，因為它提醒我們：特徵越多不一定越好，尤其在資料量只有 50 筆時，每一個新特徵都可能增加變異與過度擬合風險。

模型	特徵	RMSE	R ²	Adjusted R ²	解讀
Model A	R&D Spend	7,714.33	0.9265	0.9173	最佳測試泛化能力，模型簡潔且商業解釋強
Model B	R&D + Marketing	8,206.33	0.9168	約 0.8960	Marketing 未明顯改善測試誤差
Model C	R&D + Marketing + Admin	8,242.78	0.9161	約 0.8840	Administration 可能未提供穩定增益
Model D	All Features incl. State	9,055.96	0.8987	約 0.8350	特徵增加後誤差升高，可能過度擬合
Model E	State Only	較差	低或不穩定	低或不穩定	單靠 State 無法有效預測 Profit




圖 6-1：使用者提供之 RMSE 與 R^2 特徵數量趨勢圖




圖 6-2：依特徵組合比較 RMSE 趨勢




圖 6-3 : R^2 與 Adjusted R^2 趨勢比較

6.1 為什麼 Model A 勝出

Model A 勝出的原因可以從統計與商業兩個角度理解。統計上，R&D Spend 與 Profit 的關聯性很強，因此單一特徵已能捕捉大量訊號。當資料量很小時，額外加入弱特徵可能使模型學到測試資料中不穩定的模式，導致泛化誤差上升。

商業上，R&D Spend 代表產品開發與技術能力，這通常是新創公司獲利的根本。若一家企業投入更多研發，可能代表產品更成熟、技術門檻更高、市場競爭力更強。因此 R&D 的預測能力並非偶然，而是與商業邏輯高度一致。

這也說明模型選擇不能只追求欄位完整，而要追求「訊號密度」。一個欄位若能穩定解釋目標變數，就可能比多個弱欄位組合更有價值。Model A 是本專案中最能體現此原則的結果。

6.2 特徵數量增加後表現下降的意義

從結果表可看出，特徵數量從 1 增加到 5 時，RMSE 整體呈上升趨勢， R^2 則下降。這代表新增特徵沒有改善測試集預測能力，反而讓模型更容易捕捉雜訊。這種現象不一定代表所有新增特徵在真實世界中無用，而是代表在目前資料規模與切分設定下，它們沒有提供穩定增益。

小樣本資料常見的風險是模型對訓練資料細節過度敏感。State 經 One-Hot Encoding 後會增加欄位數，Administration 又可能與 Profit 關係不穩定，這些都可能讓模型係數變得不穩。若要更可靠地判斷這些特徵，需要更多資料或交叉驗證。

因此，本白皮書建議把 Model A 作為目前最合理的教學與報告結論，但在實務部署前仍應使用更大資料集、更多時間切分與更嚴格的驗證方式確認穩定性。

7. 特徵選擇演算法比較

除了商業導向實驗，本專案也加入五種特徵選擇方法，目的在於檢查 R&D Spend 的主導地位是否只來自某一組模型設計。若多種方法都選出相同核心特徵，代表該特徵的重要性更具穩健性。

方法	類型	核心邏輯	本案意義
Sequential Feature Selection	Wrapper	逐步搜索最佳特徵組合	驗證最少特徵下的最佳表現
RFE	Wrapper	根據模型權重遞迴移除弱特徵	檢查線性模型係數穩定性
Lasso	Embedded	以 L1 正則化壓縮弱係數	自動篩選較有用特徵
SelectKBest	Filter	根據統計關係排序特徵	獨立於模型檢查單變數關係
Random Forest Importance	Embedded	依樹模型純度提升評估重要性	提供非線性角度的特徵排序

五種方法雖然原理不同，但都指向 R&D Spend 是最強的單一特徵。這一點非常重要，因為它降低了「只是 LinearRegression 偏好某特徵」的疑慮。Filter 方法、Wrapper 方法與 Embedded 方法若都給出相似結論，表示 R&D Spend 的訊號在資料中非常明顯。

不過，特徵選擇演算法也有侷限。由於資料只有 50 筆，任何排序都可能受資料切分或離群點影響。因此演算法結果應與商業邏輯共同使用，而不是把特徵排名視為絕對真理。

在教學報告中，加入特徵選擇比較可以提升分析完整度。它讓結論不只依賴一組模型，也能展現資料科學家如何用多角度方法驗證假設。

特徵重要性金字塔

模型策略：從最小而可解釋的核心特徵開始，逐步加入特徵並檢查泛化誤差。




圖 7-1：四個特徵在本專案中的重要性定位

8. 多領域專家五回討論後的商業共識

本專案假設由 R&D 專家、Marketing 專家、銷售專家、財務分析師、州或區域政策專家以及資料科學家共同討論五回。這種設定的目的不是創造劇情，而是讓特徵解釋更接近真實決策環境。不同角色會從不同角度看同一個欄位，因此能避免單一技術視角造成偏誤。

多領域專家五回討論後的特徵共識

R&D 專家、Marketing 專家、銷售專家、財務分析師、州/區域政策專家、資料科學家共同形成的模型設計原則。




圖 8-1：多領域專家對四個特徵的共識

專家角色	主要關注	對特徵的判斷
R&D 專家	產品力與技術門檻	R&D Spend 是最直接的競爭力指標
Marketing 專家	曝光、品牌與需求創造	Marketing 是放大器，但需依附產品價值
銷售專家	客戶轉換與營收落地	銷售成果同時受產品與行銷影響
財務分析師	成本結構與獲利效率	Administration 較像成本，需檢查是否拖累模型
州/區域政策專家	稅務、人力與市場環境	State 可觀察，但樣本不足不宜做強推論
資料科學家	泛化誤差與模型穩健性	以 Adjusted R^2 、RMSE、MAE 與簡潔性選模型

第一回討論聚焦商業直覺。R&D 專家主張產品與技術是新創公司的根本；Marketing 專家認為行銷能放大產品價值；財務分析師提醒行政支出不等於價值創造。這一回形成初步假設：R&D 最重要，Marketing 次之，Administration 與 State 需驗證。

第二回討論聚焦資料限制。資料科學家指出，50 筆樣本對多特徵模型來說非常小，任何增加特徵的行為都可能造成過度擬合。州政策專家也提醒，State 的差異可能真實存在，但資料量不足以支持強烈結論。

第三回討論聚焦實驗設計。專家群同意不應只建立全特徵模型，而應從 R&D 開始逐步加入 Marketing、Administration 與 State。這讓每個特徵的增量價值都能被觀察。

第四回討論聚焦模型結果。當 Model A 取得最佳 RMSE 與 Adjusted R^2 時，技術結果與商業直覺一致。專家群認為這是強訊號：R&D Spend 不只是統計特徵，也是商業上合理的核心驅動因子。

第五回討論形成最終結論：Profit 主要由資源配置與產品技術投入驅動，而不是由 State 單獨決定。Marketing 是重要輔助，Administration 需謹慎，State 只能作為背景資訊。最終模型應兼顧指標、簡潔性與商業解釋。

9. 程式架構與實作設計

本專案的程式檔案建議命名為 50_startups_crisp_dm_v2.py。程式結構對應 CRISP-DM 六階段，並包含可重複使用的 helper functions。這種設計不只適合作業，也適合作為日後資料分析專案模板。

區塊	內容
Step 0	Import libraries
Step 1	Business Understanding comment block
Step 2	Data Understanding: head、info、describe、missing、duplicates、State counts
Step 3	Data Preparation: features、target、preprocessing setup
Helper 1	adjusted_r2_score
Helper 2	run_experiment
Step 4	Modeling: run five experiments
Step 5	Evaluation: comparison table and best model
Helper 3	get_model_coefficients
Step 6	Expert-Based Business Conclusion

run_experiment 是整個程式的核心函式。它接收 feature_columns、target_column 與 categorical_columns，內部自動建立 ColumnTransformer、Pipeline、train_test_split、模型訓練、預測與評估。這樣可以確保五組實驗使用完全一致的流程，減少手動複製程式造成的錯誤。

Adjusted R^2 函式用來修正 R^2 對特徵數量的偏好。當模型加入更多特徵時，普通 R^2 可能不下降，甚至在訓練集上上升；Adjusted R^2 則會對特徵數量進行懲罰，更適合用於比較不同複雜度模型。

get_model_coefficients 函式用來萃取 Pipeline 裡的特徵名稱與迴歸係數。因為 OneHotEncoder 會產生新的欄位名稱，所以不能只看原始欄位。透過 preprocessor.get_feature_names_out() 可以取得轉換後欄位，進一步解釋係數。

9.1 關鍵程式片段設計說明

```
preprocessor = ColumnTransformer(transformers=[("cat", OneHotEncoder(drop="first"), categorical_columns),
("num", "passthrough", numeric_columns)])
```

```
model = Pipeline(steps=[("preprocessor", preprocessor), ("regressor", LinearRegression())])

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

y_pred = model.predict(X_test)

rmse = np.sqrt(mean_squared_error(y_test, y_pred))
```

10. 風險、限制與後續改進

10.1 小樣本限制

本資料集只有 50 筆資料，因此測試集在 80/20 切分下只有 10 筆。這意味著單一切分結果可能對個別樣本非常敏感。雖然 `random_state=42` 保證可重複性，但可重複不等於絕對穩健。若要更嚴格，應加入 K-fold cross-validation 或 repeated cross-validation。

10.2 線性假設限制

`LinearRegression` 假設特徵與 Profit 之間主要是線性關係。若真實關係包含非線性、交互作用或門檻效應，線性模型可能無法完整捕捉。然而，在小資料與教學情境中，線性模型的可解釋性仍然具有優勢。

10.3 State 的解釋限制

State 可能代表多種潛在因素，但資料中沒有直接提供稅率、人力成本、城市密度或產業環境等欄位。因此 State 的係數只能被視為代理變數，不應用來做因果推論。若要研究地區因素，必須補充更豐富的外部資料。

10.4 Administration 的不穩定性

Administration 可能反映企業規模，也可能反映低效率成本。單一欄位無法區分這兩種情況，因此它的模型係數不一定具有清楚商業含義。未來可加入員工數、營收、毛利率或營運效率等欄位改善解釋。

10.5 評估方式改進

本專案使用固定 train/test split 方便教學與報告對照，但更完整的研究應使用交叉驗證、殘差分析、離群點診斷與係數信賴區間。這些方法可以更清楚評估模型穩定性與不確定性。

11. 最終決策建議

第一，若以本次模型結果與商業邏輯共同判斷，建議將 R&D Spend 視為最核心的預測變數。它在模型上有最佳單一特徵表現，在商業上也最能代表產品技術能力。

第二，Marketing Spend 應被視為重要但非獨立核心的輔助變數。它可能在真實世界中非常重要，但在本資料集的測試切分下沒有改善最佳模型。報告中應強調 Marketing 是產品價值的放大器，而不是取代產品力的根源。

第三，Administration 不應被直接解讀為利潤推動因子。若加入後模型未改善，應考慮它只是營運成本或噪音。企業決策上應控制行政成本效率，而非單純增加行政支出。

第四，State 可以加入模型測試，但不應成為主要結論。地區確實可能影響企業績效，但本資料集缺乏足夠樣本與背景變數，無法支持強烈地區因果推論。

第五，最終模型應選擇簡潔、指標良好且商業解釋合理的版本。以目前結果來看，Model A 是最適合報告主結論的模型；若要展示完整建模流程，可以同時呈現 Model B 到 Model E 作為對照。

附錄 A：YAML Prompt v2 摘要

v2 Prompt 的核心要求是生成完整 Python sklearn 程式，使用 CRISP-DM 方法解決 Kaggle 50 Startups 迴歸問題，並納入多領域專家討論後的特徵優先順序。Prompt 指定程式要執行五組實驗、比較 R^2 、Adjusted R^2 、MAE、MSE 與 RMSE，最後輸出模型比較表、最佳模型、係數與商業結論。

相較 v1，v2 最大差異是加入 expert_discussion_summary。它要求模型不只寫程式，還要以 R&D、Marketing、Sales、Finance、Regional Policy 與 Data Science 的視角解釋結果。這讓生成出來的程式與報告更像完整白皮書，而不是單純程式作業。

prompt_name: kaggle_50_startups_crisp_dm_sklearn_v2

version: v2

objective: Write a complete Python sklearn program to solve the Kaggle 50 Startups regression problem using CRISP-DM.

expert_consensus: R&D Spend is the core predictor; Marketing Spend is a supporting amplifier; Administration is uncertain; State is supporting and should not be over-interpreted.

experiments: Model A R&D only, Model B R&D + Marketing, Model C + Administration, Model D all features, Model E State only.

metrics: R2, Adjusted R2, MAE, MSE, RMSE.

final_instruction: Generate 50_startups_crisp_dm_v2.py with executable code and expert-based conclusion.

附錄 B：建議報告撰寫模板

報告撰寫時，建議先以 Business Understanding 說明為何要預測 Profit，再以 Data Understanding 介紹每個欄位。接著進入 Data Preparation，說明 State 如何編碼與 Pipeline 如何防止資料洩漏。Modeling 章節應強調五組實驗的目的，而不是只列程式碼。Evaluation 章節則要把 RMSE、 R^2 與 Adjusted R^2 放在同一張表，並說明 Model A 為何勝出。

結論章節應避免過度宣稱。較安全的說法是：在此資料集與固定測試切分下，R&D Spend 是最具預測力且最具商業解釋性的特徵；Marketing、Administration 與 State 可作為比較實驗，但未必改善測試集泛化表現。這樣的結論兼顧數據結果、商業邏輯與研究限制。

附錄 C：擴充技術討論

C.1 為什麼不能盲目使用所有欄位

在許多入門機器學習練習中，常見做法是把所有欄位都放進模型，然後直接觀察一次結果。這種做法雖然簡單，但會掩蓋特徵之間的差異。對 50 Startups 來說，四個特徵的商業含義並不相同。R&D Spend 是直接投入產品與技術的資源，Marketing Spend 是市場曝光與銷售推動，Administration 是管理成本，State 則是地區背景。如果全部混在一起，模型即使有不錯分數，也很難回答哪個因素真正重要。更好的方法是逐步加入特徵，觀察每一步是否改善測試誤差。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

C.2 為什麼 Adjusted R^2 很重要

R^2 表示模型可以解釋目標變數多少比例的變異，但它對特徵數量不夠敏感。當我們加入更多特徵時，即使特徵沒有真正幫助， R^2 也可能因為模型彈性增加而不下降。Adjusted R^2 則會根據樣本數與特徵數量進行修正。如果新增特徵無法帶來足夠解釋力，Adjusted R^2 會下降。這使它特別適合比較 Model A、Model B、Model C 與 Model D 這類不同特徵數量的模型。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

C.3 為什麼 RMSE 與 MAE 都要看

RMSE 會放大較大的錯誤，因此對離群預測更敏感；MAE 則代表平均絕對誤差，比較直觀。若某模型 RMSE 明顯高於另一模型，代表它可能在少數樣本上犯了較大錯誤。商業上，錯估利潤可能造成投資判斷錯誤，因此 RMSE 是重要指標。但 MAE 也不可忽略，因為它可以讓管理者理解平均預測誤差大約是多少金額。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

C.4 為什麼模型簡潔性是優點

在小型資料集上，簡潔模型通常比複雜模型更容易泛化。Model A 只使用 R&D Spend，雖然看似簡單，卻取得最佳測試表現。這代表模型抓到主要訊號，而沒有被其他弱特徵干擾。這種簡潔性也讓商業溝通更容易：企業可以清楚理解研發投入與利潤之間的關係，而不是面對一個難以解釋的多特徵模型。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

C.5 如何向非技術主管解釋結果

向非技術主管說明時，不需要先談 Pipeline 或 OneHotEncoder，而應先說明結論：目前資料顯示研發投入最能預測利潤。接著說明我們不是主觀判斷，而是透過五組實驗比較得出。最後補充限制：資料只有 50 筆，因此結論適合作為方向性參考，不應視為絕對因果。這樣的表達能讓主管理解模型價值，也能避免過度承諾。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

C.6 如何向技術評審解釋結果

向技術評審說明時，應強調流程嚴謹性。包括固定 random_state、使用 Pipeline 避免資料洩漏、用 OneHotEncoder(drop=first) 處理類別欄位、用 Adjusted R² 修正特徵數量影響、用多組實驗檢查特徵增量價值，以及用特徵選擇演算法驗證 R&D Spend 的穩健性。這些細節能證明專案不是只跑一次回歸，而是有設計、有比較、有解釋。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

C.7 如何改進為 v3

若要發展 v3，可以加入 K-fold cross-validation，讓每組特徵實驗不只依賴單一測試集。也可以加入殘差圖、Actual vs Predicted 圖、係數信賴區間與離群點分析。若想提高模型能力，可以比較 Ridge、Lasso、ElasticNet、RandomForestRegressor 與 GradientBoostingRegressor，但必須注意資料量小，複雜模型可能不穩。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

C.8 如何把結果變成商業策略

模型結果可以轉換成策略建議：企業應優先保障研發投入，因為研發與利潤關聯最強；行銷支出應與產品成熟度搭配，不應在產品力不足時盲目加碼；行政成本應追求效率，而非單純擴大；地區因素可作為背景參考，但不應取代對產品與財務結構的分析。這些建議把模型結果轉化成企業可執行的決策語言。

進一步來看，這個觀點也提醒我們，資料科學專案不能只依賴單一數值分數。模型要能被使用，必須同時滿足預測能力、可解釋性、穩健性與商業可溝通性。當資料規模有限時，過度複雜的模型可能讓報告看起來高級，但不一定讓決策更可靠。

因此，在本作業的脈絡下，最合理的做法是以簡潔模型作為核心結論，以其他模型作為對照實驗。這樣既能展示完整的機器學習流程，也能清楚說明為什麼最終選擇不是盲目追求更多欄位，而是追求更穩定、更合理的特徵組合。

結語

本白皮書從 CRISP-DM 方法出發，完整整理 Kaggle 50 Startups 獲利預測專案。透過商業理解、資料理解、資料準備、建模、評估與專家導向結論，我們展示了一個比單純線性迴歸更完整的分析流程。

最終結論非常明確：在目前資料與實驗設定下，R&D Spend 是最核心、最穩定且最具商業解釋性的特徵。Marketing Spend 具有輔助意義，Administration 與 State 需要謹慎測試與解讀。模型選擇應以 Adjusted R^2 、RMSE、MAE、係數解釋與商業邏輯共同決定。

這份報告的價值不只在於得到 Model A 的最佳分數，更在於建立一種分析態度：面對資料時，要先理解問題、理解欄位，再用實驗驗證假設，最後把技術結果轉換成可被商業採用的結論。

附錄 D：完整方法論延伸說明

本附錄進一步擴充本專案的方法論細節，目的在於讓白皮書不只是一份結果摘要，而是一份可以作為機器學習作業、資料科學報告與商業分析簡報基礎的完整技術文件。以下各節從商業假設、特徵語意、實驗設計、模型評估、視覺化溝通、可解釋性與風險控管等角度深入說明。

D.1 商業假設如何轉換成模型假設

商業假設是資料科學專案的起點。對 50 Startups 而言，商業上我們先假設研發、行銷、行政與地區因素會影響利潤；模型上則把這些因素轉換成特徵欄位，並觀察它們是否能降低預測誤差。這個轉換過程非常重要，因為如果商業假設不清楚，模型即使得到不錯分數，也難以解釋為何某個欄位重要。

在本專案中，R&D Spend 對應到產品與技術能力，Marketing Spend 對應到市場觸及與品牌曝光，Administration 對應到管理成本與組織規模，State 對應到區域環境。這些假設使得模型結果可以被解讀，而不是只停留在數學係數。

真正成熟的資料科學流程會在建模前先寫下假設，再用模型結果驗證或修正假設。本白皮書把特徵實驗設計成逐步加入，是因為我們想知道每個假設在資料中是否被支持。這比單純一次放入所有特徵更有分析價值。

D.2 小資料集下的模型哲學

小資料集的核心困難不是模型不夠複雜，而是資料不足以支撐太複雜的結論。50 筆資料在機器學習中屬於非常小的樣本，每一筆觀測都可能對係數與測試誤差造成明顯影響。

在這種情況下，簡單模型具有兩個優點。第一，它比較不容易過度擬合；第二，它比較容易解釋。Model A 只使用 R&D Spend，卻得到最佳測試結果，正是小資料集下簡潔模型優勢的例子。

因此，本專案不建議以複雜模型追求表面分數。若使用 Random Forest 或 Gradient Boosting，可能在訓練集上表現很好，但在新資料上不一定穩定。教學與白皮書重點應放在流程、解釋與穩健性。

D.3 特徵共線性與解釋風險

多元線性迴歸中的一個常見問題是共線性。若兩個特徵彼此高度相關，模型可能難以穩定估計各自係數。對本資料集而言，R&D Spend 與 Marketing Spend 可能都與公司規模有關，因此兩者可能存在一定程度的重疊。

這種重疊不一定會使預測失效，但會增加解釋困難。若 Marketing Spend 的係數變小，不一定代表行銷無用，可能只是它與 R&D 或公司規模共享了部分資訊。

因此，報告中應避免使用過度絕對的語句，例如「Marketing 完全沒有用」。較正確的說法是：在本資料集與本次測試切分中，加入 Marketing Spend 未明顯改善測試集泛化表現。

D.4 為什麼需要 Model E

Model E 只使用 State，看起來像是刻意建立一個很弱的模型，但它其實有重要診斷價值。它可以回答一個明確問題：單靠地理位置是否足以預測 Profit。

若 Model E 表現很差，就能支持一個保守結論：State 不應被當成主要預測因子。這個結論對防止過度解讀很重要，因為人們容易把地區差異誤認為因果因素。

透過 Model E，我們可以更有把握地說，State 可能是背景變數，而不是主導獲利的核心欄位。這讓白皮書的商業結論更嚴謹。

D.5 為什麼要保留圖表

圖表是技術白皮書的重要組成。表格能呈現精確數值，但趨勢圖能讓讀者快速理解特徵數量增加後，RMSE 與 R^2 如何變化。

使用者提供的資訊圖與模型趨勢圖，剛好補足文字報告的不足。第一張圖提供整體流程視覺摘要，第二張圖呈現特徵數量與模型表現的關係。

在商業溝通中，圖表可以降低理解門檻。對非技術讀者而言，看到 RMSE 隨特徵增加而上升，比閱讀長篇統計說明更直接。

D.6 資料科學家如何寫結論

好的模型結論不應只寫「Model A 最好」。更完整的寫法應包含原因、限制與建議。例如：Model A 以 R&D Spend 取得最佳測試表現，原因可能是研發支出與利潤高度相關，同時模型簡潔降低過度擬合風險。

接著應補充，Marketing、Administration 與 State 並非沒有商業意義，而是在本資料集與實驗設定下未提供足夠穩定的增量價值。這樣的說法比較精準，也更符合資料科學倫理。

最後要把結果轉換成決策語言：企業應優先保障研發投入，將行銷視為放大器，控制行政成本，並把地區因素作為輔助參考。

D.7 教學作業的評分觀點

若這份專案作為 HW6 作業，評分者通常不只看程式能否執行，也會看是否有清楚的問題定義、資料理解、模型比較與結果解釋。

本白皮書的設計正是為了滿足這些評分點。它使用 CRISP-DM 結構，展示 Data Understanding，採用 sklearn Pipeline，進行多模型實驗，並以表格與圖表說明結果。

相較於單純輸出一段程式碼，這樣的報告更能展現資料科學專案能力，也能說明學生理解模型背後的商業邏輯。

D.8 實務部署前應做什麼

若要把此模型用於真實企業決策，必須先擴充資料來源。50 筆資料不足以支撐正式投資或預算決策，需要更多公司、更多產業、更多時間點與更多財務欄位。

其次，需要建立驗證流程。例如使用交叉驗證檢查模型穩定性，用時間切分避免未來資訊洩漏，用外部測試集檢查泛化能力。

最後，需要建立監控機制。若未來市場環境改變，R&D 與 Profit 的關係可能也會改變，模型必須定期重訓與重新評估。

D.9 白皮書與程式碼的關係

程式碼負責產生模型與指標，白皮書負責解釋為什麼這些指標有意義。兩者缺一不可。只有程式碼，讀者可能看不懂商業意義；只有白皮書，則缺乏可重複驗證的技術基礎。

本專案建議保留 `50_startups_crisp_dm_v2.py` 作為主要程式檔，並保留 `plots/crisp_dm_v2` 內的圖表輸出。白皮書則作為最終成果文件，把程式結果整理成可讀報告。

這種分工也符合實務資料科學專案：notebook 或 script 是分析流程，PDF 或簡報是溝通成果。

D.10 State 的正確報告方式

State 是最容易被誤解的欄位。若模型中某個州別係數為正，不能直接說該州一定比較有利，因為係數可能受到樣本分布、其他特徵、資料切分與基準類別影響。

正確寫法應該是：State 可能反映區域環境差異，但在本資料集樣本數有限的情況下，其效果缺乏足夠統計強度，因此僅作輔助觀察。

這樣的寫法不但更嚴謹，也能避免把相關性誤寫成因果性。

D.11 Administration 的正確報告方式

Administration 同樣需要小心解釋。行政支出高可能代表企業規模較大，也可能代表成本控制較差。資料集沒有提供員工數、營收、效率或管理品質，所以無法判斷行政支出背後真正原因。

如果加入 Administration 後模型變差，不能簡單說行政支出有害，只能說它在本資料與模型設定下未提供穩定預測增益。

在商業建議上，較合理的表達是：企業應關注行政成本效率，而非把行政支出視為直接獲利驅動。

D.12 Marketing 的正確報告方式

Marketing Spend 在商業上通常重要，但模型結果可能顯示它未改善測試表現。這種差異並不矛盾，因為行銷效果可能是非線性、延遲性或依賴產品品質。

在 50 Startups 資料中，Marketing 也可能與公司規模或 R&D 投入重疊，因此它的獨立邊際效果不容易被線性模型完全分離。

因此，應把 Marketing 描述為重要輔助或放大器，而非在本資料中最核心的單一預測因子。

D.13 R&D 的正確報告方式

R&D Spend 是本專案最穩定的核心特徵。它在商業上代表產品與技術能力，在模型上取得最佳單一特徵結果，在特徵選擇方法中也被多次選為最重要欄位。

然而，即使 R&D 很重要，也不應宣稱只要增加研發支出就一定增加利潤。模型顯示的是統計關聯，而不是嚴格因果。

正確結論是：在此資料集中，R&D Spend 與 Profit 具有最強且最穩定的預測關係，適合做為模型核心特徵。

D.14 視覺設計與報告說服力

圖文並茂的報告能讓不同背景讀者快速抓到重點。流程圖說明專案方法，模型表格說明實驗設計，趨勢圖說明模型表現，金字塔圖說明特徵重要性。

這些圖表不是裝飾，而是把技術推論變成可以溝通的證據。特別是當報告需要給老師、同學或非技術主管閱讀時，視覺化能大幅提升理解效率。

因此，本 PDF 同時包含使用者提供的資訊圖、特徵趨勢圖，以及新繪製的 CRISP-DM 工作流、專家共識圖與特徵金字塔。

D.15 最終方法論總結

本專案的方法論可以濃縮為一句話：先用商業邏輯提出假設，再用資料與模型逐步驗證，最後用可解釋的方式回到商業決策。

這也是 CRISP-DM 的精神。資料科學不是只為了建模，而是為了解決問題。50 Startups 雖然是小型教學資料集，但透過嚴謹流程，仍能展示完整的分析思維。

未來若擴充到更大型資料，這套流程仍可沿用：先理解商業問題，分析資料欄位，建立可重複 Pipeline，設計特徵實驗，用多指標評估，最後產出可行建議。

附錄 E：給不同讀者的閱讀摘要

讀者類型	最應關注內容	一句話摘要
程式開發者	Pipeline、ColumnTransformer、run_experiment	確保流程可重複且避免資料洩漏
資料科學學習者	特徵實驗與評估指標	不要只看 R^2 ，要比較 RMSE 與 Adjusted R^2
商業分析師	R&D、Marketing、Administration、State 的解讀	R&D 是核心，Marketing 是輔助，其他需驗證
老師或評分者	CRISP-DM 完整性與報告結構	專案有從問題定義到結論的完整流程
企業決策者	最終建議與限制	優先保障研發投入，但不要把模型視為因果證明

附錄 F：逐段式技術審查與實務延伸

F.1 從資料取得到可重複實驗

資料來源固定為公開 CSV 連結，這使得任何人都可以重新執行相同程式並得到相同輸入。可重複性是資料科學作業的重要品質，因為模型結果如果不能重現，就很難被驗證。

在 v2 程式中，random_state=42 固定了資料切分，test_size=0.2 固定了訓練與測試比例。這種設定不是唯一正確答案，但它讓不同特徵實驗在同一基準下比較，避免因切分不同造成不公平。

若未來要進一步提升嚴謹度，可以把單次切分改成 K-fold cross-validation。如此每一筆資料都會在不同回合中作為驗證資料，能更穩定估計模型在未知資料上的平均表現。

F.2 從欄位名稱到資料語意

欄位名稱看似簡單，但資料語意才是分析核心。R&D Spend 不是單純數字，而是研發活動的資金代理；Marketing Spend 不是單純成本，而是市場觸及能力的代理；Administration 不是單純支出，而是組織運作成本的代理。

當我們把欄位放入模型時，其實是在假設這些代理變數與 Profit 之間存在某種穩定關係。若代理變數太粗略，模型解釋就可能失真。例如 State 只能代表州別，卻無法直接告訴我們稅率、人才密度或產業聚落。

因此，白皮書在欄位分析中反覆強調「可觀察」與「不可過度解讀」的差異。可以觀察代表資料中可能有訊號；不可過度解讀代表目前資料不足以支持強因果結論。

F.3 從模型指標到商業語言

模型指標是技術語言，商業建議是決策語言。RMSE 下降代表預測誤差降低，但企業主管更想知道這是否能改善預算配置。Adjusted R^2 較高代表模型在考慮複雜度後更合理，但商業讀者更關心哪些支出應優先。

因此，本專案把 Model A 的技術結果轉譯為商業結論：研發投入是目前最穩定的獲利訊號。這種轉譯不是把統計結果簡化，而是把它放在可行動的決策框架中。

同時，白皮書也保留限制聲明。模型結果不能證明增加研發支出一定導致利潤上升，只能說在這份資料中，研發支出與利潤呈現最強預測關係。這種表達更負責任。

F.4 從結果表到模型故事

結果表列出 RMSE、 R^2 與 Adjusted R^2 ，但真正有說服力的是背後的故事。Model A 最佳，說明核心訊號集中在 R&D；Model B 與 C 未改善，說明新增特徵不一定帶來泛化增益；Model D 更差，提醒類別特徵在小樣本下可能增加複雜度。

這個故事符合專家共識，也符合技術結果。白皮書的任務就是把結果表變成清楚的敘事，使讀者理解為什麼最終選擇簡潔模型，而不是盲目追求全欄位模型。

若沒有這種敘事，讀者可能只看到一串數字，卻不知道如何判斷。好的資料科學報告必須把數字、圖表、模型與商業邏輯串在一起。

F.5 從圖像到證據鏈

第一張資訊圖提供整體專案摘要，讓讀者快速掌握 CRISP-DM、主要實驗、特徵選擇與最終結論。第二張圖則展示 RMSE 與 R^2 隨特徵數量變化的趨勢。這兩張圖共同建立視覺證據鏈。

本白皮書另外新增工作流圖、專家共識圖與特徵金字塔，目的在於讓不同讀者都能找到入口。技術讀者可以看模型表，商業讀者可以看共識圖，初學者可以看流程圖。

圖表不是取代文字，而是強化文字。當圖表與文字指向同一結論時，報告的可信度會提高。

F.6 從 sklearn 實作到工程品質

很多初學者會先對整份資料做 `get_dummies`，再進行 `train_test_split`。這在簡單作業中可能可行，但工程上較不嚴謹。Pipeline 的好處是把資料轉換與模型綁在一起，避免訓練與預測流程分離。

ColumnTransformer 則讓不同欄位接受不同處理。數值欄位直接 `passthrough`，類別欄位使用 `OneHotEncoder`。這種結構清楚、可擴充，也方便未來加入 `StandardScaler`、`PolynomialFeatures` 或其他處理器。

因此，v2 程式雖然使用的是簡單線性迴歸，但架構本身具有工程品質。它不是一次性的腳本，而是可以擴展成更完整機器學習流程的基礎。

F.7 從特徵選擇到模型治理

特徵選擇不只是提升分數，也是一種模型治理。它讓我們有理由保留或移除欄位，而不是憑直覺決定。當五種方法都支持 R&D Spend 的重要性時，模型結論更容易被接受。

不過，模型治理也要求我們承認不確定性。特徵選擇在小資料上可能不穩，若換一個切分或加入新資料，排序可能改變。因此報告應把結果稱為目前資料下的證據，而不是永久真理。

這種謹慎態度能提升白皮書專業度。成熟的資料科學家不只會展示結果，也會說明結果在什麼條件下成立。

F.8 從專家討論到跨部門協作

多領域專家討論是本專案的一個重要設計。R&D 專家重視產品，Marketing 專家重視市場，財務分析師重視成本，區域政策專家重視環境，資料科學家重視泛化能力。

真實企業中的資料科學專案通常也是跨部門合作。若只由技術人員決定模型，可能忽略業務脈絡；若只由業務人員解讀資料，可能忽略統計限制。

因此，白皮書把專家共識寫入模型結論，能讓技術與商業語言彼此對齊。這也是 CRISP-DM 強調商業理解的原因。

F.9 從作業成果到作品集展示

這份專案若放入個人作品集，可以展示三種能力：第一是 Python 與 sklearn 實作能力；第二是資料科學方法論能力；第三是把分析結果寫成白皮書與視覺化文件的溝通能力。

作品集不一定只放程式碼。若能同時提供程式、圖表、報告與結論，會比單一 notebook 更完整。尤其對初學者而言，能清楚解釋為何這樣設計，比單純套用演算法更重要。

因此，本 PDF 可以作為專案展示文件，搭配 GitHub 程式碼、plots 輸出資料夾與 README 使用。

F.10 從 v2 到未來研究方向

v2 已完成 CRISP-DM、五組特徵實驗、特徵選擇、圖表與專家結論。未來 v3 可以加入交叉驗證、殘差診斷、VIF 共線性檢查、係數信賴區間與模型比較。

若要更接近真實商業問題，也可以擴充資料欄位，例如公司成立年限、員工數、產業別、營收、毛利率、資本額、市場規模與地區經濟指標。這些欄位會讓模型更有解釋力。

最終目標不是讓模型更複雜，而是讓模型更可靠。每一次擴充都應回到核心問題：新特徵是否改善泛化能力，是否有商業意義，是否能被決策者理解。

附錄 G：最終白皮書摘要版

本專案以 Kaggle 50 Startups 資料集為例，使用 CRISP-DM 方法建立完整的獲利預測流程。資料包含研發支出、行銷支出、行政支出、州別與利潤。模型使用 scikit-learn 的 LinearRegression、Pipeline、ColumnTransformer 與 OneHotEncoder，並設計五組特徵實驗比較不同欄位組合的預測效果。

實驗結果顯示，僅使用 R&D Spend 的 Model A 在測試集上表現最佳，RMSE 為 7,714.33， R^2 為 0.9265，Adjusted R^2 為 0.9173。這表示研發支出是目前資料中最具預測力的特徵。隨著 Marketing、Administration 與 State 加入，模型未獲得更佳泛化表現，反而可能受到小樣本與弱特徵影響。

從商業角度來看，R&D Spend 代表產品開發、技術能力與創新能力，因此是新創公司獲利的重要基礎。Marketing Spend 可視為市場放大器，但其效果依賴產品力；Administration 代表營運成本，需謹慎評估；State 可反映地區差異，但在 50 筆樣本下不宜過度解讀。

最終建議是：在本作業與資料條件下，以 Model A 作為主要結論模型，並以其他模型作為對照實驗。報告應強調模型選擇不是只看 R^2 ，而是同時考慮 Adjusted R^2 、RMSE、MAE、係數解釋、模型簡潔性與商業邏輯。這樣的分析流程比單純跑一次回歸更完整，也更符合資料科學專案的專業要求。

附錄 H：逐項審查清單與報告深化說明

為了讓本白皮書更接近完整技術文件，本附錄提供逐項審查清單與深化說明。這些內容可協助讀者檢查專案是否符合資料科學工作流、是否具備商業解釋、是否避免常見技術錯誤，以及是否能被轉化為作業報告、作品集或實務簡報。

H.1 問題定義審查

一個好的機器學習專案必須先回答「為什麼要做」。在本題中，若只說要預測 Profit，問題定義仍不完整。更完整的說法是：新創公司希望理解不同支出對利潤的關聯，並用模型輔助資源配置。這樣的定義讓技術任務與商業價值連結起來。

問題定義也應包含使用者與決策情境。可能的使用者包含創辦人、投資人、財務分析師與商業顧問。不同使用者關心的內容不同：創辦人關心資源配置，投資人關心獲利潛力，財務分析師關心成本結構。

因此，在報告開頭明確描述商業問題，可以讓後續所有模型選擇都有依據。這也是 CRISP-DM 把 Business Understanding 放在第一階段的原因。

H.2 資料品質審查

資料品質審查包含缺失值、重複列、資料型態與欄位分布。即使 50 Startups 通常很乾淨，仍應在程式中列出 `df.info()`、`df.describe()`、`df.isnull().sum()` 與 `duplicated().sum()`。這不是形式，而是讓報告可檢查。

若資料存在缺失值，必須決定刪除、補值或保留；若存在重複值，必須判斷是否是資料錯誤；若類別欄位分布不均，可能影響模型對該類別的估計。這些問題在小資料集中尤其敏感。

本專案資料量小，因此每一筆資料的重要性都很高。資料品質檢查不是例行公事，而是確保模型結論不被資料問題扭曲的必要步驟。

H.3 欄位合理性審查

每個欄位都應被問三個問題：它是否有商業含義？它是否能在預測時取得？它是否可能造成誤導？R&D Spend 通常符合三者，因為它有明確商業意義，也可在公司財務資料中取得。

Marketing Spend 也有明確含義，但它可能與公司規模或 R&D 投入重疊。Administration 的含義較模糊，因為它既可能代表組織規模，也可能代表管理成本。State 則更像背景變數，容易被誤解為因果因素。

這樣的欄位審查能避免盲目建模。資料科學不是把所有可用欄位都塞進模型，而是判斷哪些欄位能提供穩定且可解釋的訊號。

H.4 實驗公平性審查

五組模型實驗必須在相同條件下比較。若 Model A 與 Model D 使用不同 `random_state` 或不同測試比例，結果就不公平。v2 程式固定 `test_size=0.2` 與 `random_state=42`，確保差異主要來自特徵組合。

每個模型也應使用相同的評估指標。若某模型看 RMSE，另一模型看 R^2 ，就可能選擇不一致。統一比較表能讓模型選擇更透明。

公平性審查的目的，是讓模型比較具有可解釋性。當我們說 Model A 最好時，讀者知道這不是因為實驗設定偏袒，而是因為在相同條件下表現較佳。

H.5 模型解釋性審查

線性迴歸的優點是可解釋。每個係數都代表在其他特徵固定時，該欄位增加一單位與 Profit 的關聯方向與幅度。然而，解釋係數時必須注意尺度、共線性與資料限制。

若模型只用 R&D Spend，係數解釋相對直觀；若模型加入多個特徵，係數會受到其他欄位控制後的影響，不再是單純相關。State 經 One-Hot Encoding 後，其係數更是相對於基準州別的差異。

因此，報告應以係數作為輔助解釋，而不是唯一證據。更穩健的做法是同時看模型表現、特徵選擇結果與商業邏輯。

H.6 過度擬合審查

過度擬合是小資料集最常見的問題。當模型加入更多特徵時，它可能在訓練資料上更貼合，但在測試資料上表現變差。本專案中，特徵增加後 RMSE 上升，就是重要警訊。

過度擬合不一定只有複雜模型才會發生。即使是線性迴歸，在樣本少且特徵多的情況下，也可能學到不穩定係數。State 編碼後增加欄位數，Administration 關係不穩，都可能提高此風險。

因此，白皮書選擇簡潔模型，不是因為懶得使用更多欄位，而是因為評估結果支持簡潔模型更能泛化。

H.7 圖表解讀審查

圖表必須服務論點。RMSE 趨勢圖的用途是展示特徵增加後誤差變化； R^2 趨勢圖的用途是展示解釋力變化；特徵金字塔則用來說明商業重要性排序。

圖表標題、座標軸與圖說都應清楚。若圖表無法讓讀者在十秒內理解重點，則需要補充文字說明。

本報告中的圖表共同支持同一結論：R&D 是核心特徵，增加特徵不必然改善模型，State 與 Administration 需要謹慎。

H.8 結論語氣審查

資料科學報告最忌諱過度肯定。正確語氣應該是「在本資料集與實驗設定下，結果顯示……」。這樣能保留條件與限制，避免把相關性寫成因果性。

例如，不應寫「只要增加 R&D 就一定增加 Profit」，而應寫「R&D Spend 在本資料集中是最具預測力的特徵，且具備合理商業解釋」。這兩種說法專業程度差異很大。

結論語氣的謹慎，能讓白皮書更可信。專業不是把話說滿，而是知道資料能支持什麼、不能支持什麼。

H.9 作業繳交審查

若作業要求包含程式與報告，建議提交 Python 檔、圖表資料夾、PDF 白皮書與簡短 README。README 可以列出如何執行程式、輸出位置、主要結果與最佳模型。

程式中應避免硬編碼本機路徑，盡量使用相對路徑或自動建立輸出資料夾。這樣老師或同學在不同電腦上也能執行。

報告中應保持圖表與結果一致。若程式重新執行後結果不同，需要檢查 random_state、資料來源與套件版本。

H.10 作品集展示審查

若要放到個人網站或 GitHub，建議用 README 呈現專案摘要，PDF 作為完整白皮書，程式檔作為可驗證實作，plots 資料夾作為視覺成果。

作品集讀者通常不會看完所有程式，因此首頁應先展示問題、方法、最佳結果與主要結論。再提供連結給想深入的人閱讀白皮書或程式。

這種呈現方式能同時展示技術能力與溝通能力。對資料分析或 AI 工程學習者而言，溝通能力往往與寫程式同等重要。

H.11 實務化審查

若企業真的要使用此模型，必須先確認資料來源是否定期更新、欄位定義是否一致、預測對象是否與訓練資料相似，以及模型結果是否經過外部驗證。

實務化也需要考慮維護。若未來市場環境改變，R&D 與 Profit 的關係可能弱化或改變，模型需要定期監控。若資料分布偏移，原本最佳模型可能不再最佳。

因此，本作業的模型適合作為方法示範與初步洞察，不應直接視為企業級決策系統。

H.12 最終審查總結

綜合所有審查項目，本專案具備完整的 CRISP-DM 結構、清楚的欄位解釋、合理的 sklearn Pipeline、五組可比較的特徵實驗、多指標評估、圖表佐證與專家導向結論。

最重要的技術結論是：Model A 以 R&D Spend 取得最佳測試表現，代表在目前資料中，簡潔模型比全特徵模型更具泛化能力。

最重要的商業結論是：研發投入是獲利預測的核心訊號，行銷是輔助放大器，行政與地區因素需要實驗驗證與謹慎詮釋。

附錄 I：關鍵名詞、評估指標與報告用語說明

I.1 CRISP-DM

CRISP-DM 是一套跨產業資料探勘流程，強調資料科學專案應從商業理解開始，而不是從模型開始。它包含商業理解、資料理解、資料準備、建模、評估與部署六個階段。本專案採用這個框架，是為了讓 50 Startups 題目不只是線性迴歸練習，而是完整的商業分析流程。

在作業報告中使用 CRISP-DM 的好處是結構清楚。讀者可以知道每個章節扮演什麼角色，也能檢查專案是否從問題定義走到結論。對初學者而言，CRISP-DM 能避免直接寫程式卻不知道分析目的的情況。

I.2 Multiple Linear Regression

多元線性迴歸用多個特徵預測一個連續型目標變數。它假設目標變數可以用特徵的線性組合近似。雖然模型簡單，但優點是可解釋性高，特別適合像 50 Startups 這種需要說明支出與利潤關係的題目。

在本專案中，LinearRegression 不只是預測工具，也是解釋工具。透過係數可以觀察每個特徵對 Profit 的影響方向；透過特徵實驗可以觀察不同欄位組合對預測誤差的影響。

I.3 Pipeline

Pipeline 是 sklearn 中用來串接資料前處理與模型訓練的工具。它可以確保訓練與測試使用同一套轉換流程，減少手動處理造成的不一致。對需要 One-Hot Encoding 的資料來說，Pipeline 特別有用。

本專案把 ColumnTransformer 和 LinearRegression 放入 Pipeline，讓每一組實驗都能用相同流程執行。這提高了程式可維護性，也讓實驗比較更公平。

I.4 ColumnTransformer

ColumnTransformer 可以針對不同欄位使用不同處理方式。數值欄位可以直接通過，類別欄位則可以進行 One-Hot Encoding。這比手動拆資料更清楚，也更容易擴充。

在 50 Startups 中，State 是類別欄位，其他支出欄位是數值欄位。ColumnTransformer 正好可以把這兩種欄位分開處理，再合併成模型可用的矩陣。

I.5 One-Hot Encoding

One-Hot Encoding 將類別文字轉換成多個 0/1 欄位，使線性模型能處理類別資料。若 State 有三個州別，編碼後會變成代表不同州別的指示欄位。

使用 drop="first" 可以避免虛擬變量陷阱。它會保留其中幾個州別欄位，把被移除的州別作為基準。這樣模型係數比較穩定，也更符合線性迴歸需求。

I.6 RMSE

RMSE 是 Root Mean Squared Error，代表預測誤差平方平均後再開根號。它會放大較大的錯誤，因此對嚴重預測失誤很敏感。若兩個模型的 RMSE 差距明顯，通常 RMSE 較低的模型在測試集上更穩。

本專案中 Model A 的 RMSE 為 7,714.33，是主要實驗中最佳結果。這表示只用 R&D Spend 的模型，在測試集平均誤差規模上比加入更多特徵的模型更好。

I.7 R^2 與 Adjusted R^2

R^2 表示模型解釋目標變數變異的比例。 R^2 越高，代表模型解釋能力越強。但 R^2 有一個問題：當加入更多特徵時，它可能不會明顯下降，因此容易偏好複雜模型。

Adjusted R^2 會根據特徵數量進行修正。如果新特徵沒有足夠貢獻，Adjusted R^2 會下降。本專案使用 Adjusted R^2 作為重要比較標準，是為了避免盲目增加特徵。

I.8 MAE

MAE 是 Mean Absolute Error，代表平均絕對預測誤差。它不像 RMSE 那樣放大大誤差，因此更直觀。若要向非技術讀者解釋模型平均差多少金額，MAE 通常比 MSE 更容易理解。

在模型評估時，MAE 與 RMSE 應一起看。RMSE 能提醒模型是否有大錯誤，MAE 則提供平均誤差感受。兩者共同使用能讓模型評估更完整。

I.9 Overfitting

過度擬合是指模型太貼合訓練資料中的細節與噪音，導致在新資料上表現變差。小資料集特別容易發生過度擬合，因為模型能學到的資料樣本太少。

本專案中，當特徵增加時 RMSE 反而上升，這可能是過度擬合或弱特徵干擾的訊號。因此最終選擇 Model A，並不是因為它最簡單，而是因為它在測試表現與商業解釋上都最合理。

I.10 Business Interpretation

商業解釋是把模型結果轉換成決策語言的過程。資料科學報告不能只列出 RMSE 和 R^2 ，也要說明這些結果對企業有什麼意義。

本專案的商業解釋是：R&D Spend 是核心獲利訊號，Marketing Spend 是價值放大器，Administration 是需要控管的營運成本，State 是可觀察但不可過度推論的背景因素。這樣的說法比單純排名更有實務價值。

附錄 J：完整口頭報告稿與答辯準備

如果要把本白皮書轉換成課堂口頭報告，可以用以下邏輯說明：本專案使用 Kaggle 50 Startups 資料集，目標是預測新創公司的 Profit。與一般做法不同，我們不是直接把所有欄位放進模型，而是先依照 CRISP-DM 方法釐清商業問題，再根據 R&D、Marketing、Administration 與 State 的商業語意設計五組特徵實驗。這樣可以更清楚回答每個欄位是否真的有幫助。

第一個重點是 Business Understanding。新創公司資源有限，必須決定資金要投入研發、行銷還是行政管理。如果能知道哪些支出與利潤最相關，就能幫助企業做更好的預算配置。這使得本題不只是數學題，而是一個資源配置與獲利能力分析問題。

第二個重點是 Data Understanding。R&D Spend 代表產品與技術能力，Marketing Spend 代表市場曝光，Administration 代表營運管理成本，State 代表地區背景，Profit 則是模型要預測的目標。這些欄位雖然少，但每個欄位的商業意義不同，所以不能用同一種方式解讀。

第三個重點是 Data Preparation。由於 State 是文字類別欄位，不能直接放入 LinearRegression，因此使用 OneHotEncoder(drop="first") 轉成數值欄位。同時使用 Pipeline 與 ColumnTransformer 封裝前處理與模型，避免訓練集與測試集資料轉換不一致，也能防止資料洩漏。

第四個重點是 Modeling。五組模型分別是：Model A 只用 R&D Spend，Model B 加入 Marketing Spend，Model C 再加入 Administration，Model D 使用所有特徵包含 State，Model E 只用 State。這樣的設計能逐步檢查每個特徵的增量價值，而不是盲目使用全部欄位。

第五個重點是 Evaluation。評估時不能只看 R^2 ，因為 R^2 可能偏好特徵較多的模型。本專案同時使用 Adjusted R^2 、RMSE、MAE、MSE 與 R^2 。結果顯示 Model A 的 RMSE 最低， R^2 與 Adjusted R^2 也最好，代表在目前測試集上，R&D Spend 是最穩定的核心特徵。

第六個重點是 Business Conclusion。模型結果與專家討論一致：R&D Spend 是核心獲利驅動因子，Marketing Spend 是輔助放大器，Administration 可能只是營運成本，State 則只能作為地區背景觀察。這個結論不應被解讀為因果證明，而應被視為在目前資料條件下最合理的預測與解釋方向。

如果老師問為什麼不用所有特徵，回答應該是：因為本資料集只有 50 筆，加入更多特徵可能造成過度擬合；而實驗結果也顯示全特徵模型的 RMSE 較高，Adjusted R^2 較低。因此選擇 Model A 不是因為忽略其他欄位，而是因為模型比較與商業邏輯都支持它。

如果老師問 State 是否重要，回答應該是：State 可以觀察，但不是主要特徵。它可能反映市場環境、稅務、人力成本與創業資源差異，但資料量太小，州別資訊不足以支撐強烈推論。Model E 只使用 State 的目的，就是證明地點本身不足以準確預測 Profit。

如果老師問這份專案如何改進，回答可以分成三點。第一，加入 K-fold cross-validation，提高結果穩定性。第二，加入殘差分析、VIF 共線性檢查與係數信賴區間。第三，擴充資料欄位，例如員工數、產業別、營收、公司年齡、地區經濟指標等。這些改進能讓模型更接近真實商業應用。

附錄 K：最終提交檢核說明

在正式提交本作業之前，建議先檢查四件事。第一，程式是否可以從頭到尾執行，且不需要依賴本機特殊路徑。第二，輸出的模型比較表是否與白皮書中的數字一致。第三，所有圖表是否能正常開啟，且圖說能清楚說明用途。第四，結論是否同時包含技術指標與商業解釋，而不是只列出最佳模型名稱。

若要把本專案整理成資料夾，可以建立 sources、plots、reports 與 scripts 四個區域。sources 保存原始資料或資料來源說明，plots 保存所有視覺化輸出，reports 保存 PDF 白皮書與摘要，scripts 保存 Python 程式。這樣的架構能讓專案乾淨、可維護，也方便未來擴充。

對於老師或評審而言，最容易加分的部分是清楚的實驗邏輯。五組模型不是任意排列，而是從最可能重要的 R&D Spend 開始，逐步加入 Marketing、Administration 與 State。這讓每一個模型都有明確目的，也讓最終選擇 Model A 更有說服力。

對於學習者而言，這份白皮書最重要的啟發是：機器學習不是把資料丟進演算法就結束，而是要先理解問題，再設計實驗，接著用指標與圖表檢查結果，最後回到商業語言做結論。這種完整流程才是資料科學專案真正的價值。

最後，本專案雖然以簡單線性迴歸為核心，但其精神可以延伸到更複雜的任務。無論未來使用決策樹、隨機森林、梯度提升或神經網路，都仍然需要商業理解、資料品質檢查、實驗設計、模型評估與謹慎解釋。模型可以更換，但方法論應該保持嚴謹。

補充說明：本白皮書刻意保留完整的推論過程，是因為資料分析的可信度不只來自最後分數，也來自每一步是否合理。當讀者能看到問題定義、欄位理解、模型設計、結果比較與限制聲明，就能更清楚判斷結論是否可靠。這也是本專案選擇以長篇技術白皮書呈現的原因。

補充說明：若未來要將此成果發展為互動式網頁或儀表板，可以把五組模型結果做成可切換圖表，讓使用者自行選擇特徵組合並觀察 RMSE、 R^2 與 Adjusted R^2 的變化。這樣能讓學習者更直觀理解特徵選擇與模型泛化之間的關係。